

# LLM 기반 민원 분류 및 법률 문서 검색 모델 추천 보고서

본 보고서는 제시된 6개의 LLM(KoBERT, klue/RoBERTa-large, BGE-m3, KoSimCSE, Solar 10.7B, EXAONE-3.0-7.8B)을 바탕으로, **민원 내용 분류**와 **범용 법률 문서 검색**이라는 두 가지 핵심 과제에 가장 적합한 모델 2종을 선정하고 그 이유를 분석합니다.

## 1. 민원 내용 분류 (Classification) 최적 모델: klue/RoBERTa-large

민원의 카테고리나 담당 부서를 정확하게 분류하는 작업에는 **klue/RoBERTa-large**가 가장 적합합니다.

- 정교한 한국어 이해도:** 뉴스, 웹 문서, 청와대 국민청원 등 대규모 한국어 코퍼스로 학습되어 민원에 자주 등장하는 행정 용어와 일상어의 혼합 표현을 정확히 이해합니다.
- 효율성과 성능의 균형:** 약 337M 파라미터로, 생성형 모델에 비해 매우 가볍고 추론 속도가 빠릅니다. 소량의 민원 데이터로 파인튜닝(Fine-tuning) 시 분류 정확도가 뛰어납니다.
- KoBERT 대비 우위:** 같은 인코더 계열인 KoBERT보다 학습 데이터의 양과 질, 파라미터 크기 측면에서 우위에 있어 더 높은 성능을 보장합니다.

## 2. 범용 법률 문서 검색 (Retrieval) 최적 모델: BGE-m3

방대한 법률 조문, 판례 등을 검색하는 작업에는 **BGE-m3**가 가장 이상적입니다.

- 긴 문맥(Long Context) 지원:** 일반적인 임베딩 모델(512 토큰)과 달리 최대 8,192 토큰까지 처리할 수 있어, 길이가 매우 긴 법률 문서를 온전히 임베딩하고 잘림 없이 검색할 수 있습니다.
- 하이브리드 검색:** 의미 기반의 밀집 검색(Dense Retrieval)과 키워드 매칭(Sparse Retrieval, BM25)을 동시 지원하여 전문 용어가 중요한 법률 검색에서 정확도를 극대화합니다.

### 참고: BGE-m3의 한국어 지원 여부

BGE-m3는 100개 이상의 다국어를 지원하며, **한국어가 확실하게 포함되어 있습니다**. 다국어 임베딩에 특화되어 있어 한국어 검색 정확도가 매우 우수하며, 현재 국내 다양한 RAG(검색 증강 생성) 시스템 구축 및 사내 문서 검색 엔진에 표준적으로 널리 사용되고 있습니다.

### 3. 6개 후보 모델 비교 요약

| 모델명                | 주요 목적     | 문맥 길이    | 평가 및 권장 용도                        |
|--------------------|-----------|----------|-----------------------------------|
| klue/RoBERTa-large | 텍스트 분류/이해 | 512 토큰   | [선정] 민원 카테고리/부서 분류에 최적            |
| BGE-m3             | 검색/임베딩    | 8,192 토큰 | [선정] 긴 법률 문서 검색/RAG 구축에 최적        |
| KoBERT             | 텍스트 분류    | 512 토큰   | 경량이나 RoBERTa-large 대비 성능 열세       |
| KoSimCSE           | 문장 유사도    | 512 토큰   | 짧은 문장 매칭용. 긴 문서 검색 부적합            |
| Solar 10.7B        | 텍스트 생성    | 4,096 토큰 | 생성형 LLM. 단순 분류/검색용으로 리소스 소모 큼     |
| EXAONE-3.0-7.8B    | 텍스트 생성    | 8,192 토큰 | 생성형 LLM. 검색 결과를 바탕으로 최종 답변 생성에 적합 |

#### 최종 추천 파이프라인 구조:

접수된 민원은 **klue/RoBERTa-large**를 통해 신속하게 카테고리를 분류하고, 민원 해결 및 답변에 필요한 법률적 근거는 **BGE-m3**를 활용하여 자체 법률 Vector DB에서 검색하는 2-Track 하이브리드 구조를 강력히 권장합니다.