

공공 민원 상담 데이터 셋 — 탐색적 데이터 분석

AI Hub မှ ဒေါင်းလုဒ်ရယူထားသော ကိုရီးယား "공공 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터" ကို zip ဖိုင် ၂၄ ခုအတွင်းမှ JSON ဖိုင် ၁၂၁,၃၆၆ ခုလုံးကို တိုက်ရိုက်ဖွင့်ဖတ်ပြီး လေ့လာသုံးသပ်ထားသည့် EDA dashboard ဖြစ်သည်။ ဤဒေတာသည် ဌာန ၁၇ ခု (ယဉ်ကျေးမှုအဖွဲ့အစည်း၊ ဗဟိုအစိုးရဌာန၊ ဒေသန္တရအစိုးရ) ၏ မေးမြန်းချက်များကို Training/Validation နှစ်ပိုင်းခွဲပြီး 分類(classification)၊ 요약(summary)၊ 질의응답(QA) — task သုံးမျိုးအတွက် instruction-tuning ပုံစံဖြင့် label တပ်ထားသည်။

출처 AI Hub · 24.공공 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터 생성 scripts/eda.py

9,132

원본 상담 건수 (원천데이터)

Training 8,085 · Validation 1,047

112,234

Instruction 샘플 (라벨링데이터)

Training 99,745 · Validation 12,489

17

데이터 출처 기관 수

문화기관 1 · 중앙행정기관 3 · 지방행정기관 13


24 zip

원본 압축 파일

JSON 121,366개 · 약 696MB

zip ဖိုင်အမည်များက TS_국립아시아문화전당 / TS_중앙행정기관 / TS_지방행정기관 ဟုခွဲထားပြီး၊ ၎င်းအောက်တွင် ဗဟိုဌာန ၃ ခု (고용노동부·국토교통부·중소벤처기업부) နှင့် ဒေသန္တရအစိုးရ ၁၃ ခု ပါဝင်သည်။

기관 유형별 상담 건수 — Training vs Validation



커버리지 주의: Validation에는 17개 출처 기관 중 **5개(고용노동부·국토교통부·중소벤처기업부·성남시·안양시)**만 포함되어 있습니다. 서울시·제주특별자치도를 포함한 지방행정기관 11곳은 Validation에 전혀 등장하지 않으므로, Validation 성능만으로 전체 지역 커버리지를 판단하기는 어렵습니다.

기관별 상담 건수 순위 (Training, 17개 출처)

▶ 국토교통부가 최다, 의정부시가 최소

국토교통부	1,870건
서울시	1,435건
고용노동부	1,080건
중소벤처기업부	1,014건
국립아시아문화전당	841건
성남시	798건
제주특별자치도	429건
천안시	146건
부천시	119건
화성시	106건
안양시	93건
경상북도	85건
용인시	27건
파주시	16건
경상남도	11건

울산광역시

9건

의정부시

6건

부서(consulting_category) 상위 항목

미분류·"- " 제외, 실제 부서명만 표시 (문화기관은 전량 미분류)

건설안전과	207건
경영 전략	207건
건축안전과	174건
인사/노무	168건
수출입	167건
대중교통과	138건
건설과	84건
문화관광	10건

02 · 핵심 발견

문화전당은 "전화상담", 나머지는 "서면 민원"입니다

consulting_content의 시작 문구를 전수 검사한 결과, **국립아시아문화전당**(97%)은 상담원 ↔고객의 전화 통화 **전사록**이고, **중앙·지방행정기관**(99%+)은 제목/질문/답변으로 구성된 **서면 민원 Q&A**입니다. 같은 컬럼(consulting_content)이지만 성격이 전혀 다른 두 종류의 텍스트가 섞여 있다는 점은, 모델 학습·평가 시 반드시 고려해야 할 구조적 특징입니다.

PHONE · 국립아시아문화전당

source_id 001899 · consulting_turns 42 · consulting_length 411자

상담원: 안녕하십니까? 국립 아시아 문화 전당 ▲▲▲입니다. 제가 무엇을 도와드릴까요?

고객: 저희가 내일 2시 30분에 어... 전당 투어를 예약을 했는데 관련해서 좀 알아보려고요.

상담원: 네, 어떤 건 때문에 그러십니까?

고객: 전당 투어를 하게 되면 음... 어떤 코스로 이어지는지 혹시 좀 전시 위주로 보고 싶은데요.

상담원: 고객님의 전당 투어는요. 투어 신청을 고객님의께서 직접 하셨을 때 홈페이지에서 확인 가능합니다만...

상담원/고객 발화가 번갈아 이어지는 대화체 · 평균 40턴

WRITTEN · 고용노동부

source_id 701133 · consulting_turns 2 · consulting_length 160자

Q : 프리랜서 2차 긴급재난지원금을 관계부처의 잘못된 안내로 이의제기 기간이 지났다고 50만 원을 못 받는다고 해서 문의드립니다. 확인 부탁드립니다.

A : 우리 부 빠른 인터넷 상담은 일반적인 고용노동 관련 사항에 대한 간단히 답변하는 창구로서 전산조회 등 실무처리가


불가합니다.

1차 150만 원 지원이 이루어진 기수혜자 2차 50만 원 지원대상은 코로나19 긴급 고용안정지원금을...

Q(질문) → A(답변) 1회 교환으로 끝나는 게시판형 민원 · 항상 2턴

턴(turn) 수 분포 — 형식별 비중 (Training, 각 형식 내 %)

서면 민원은 100%가 "2턴"에 몰려 있고, 전화상담은 20턴 이상에 폭넓게 퍼져 있습니다




03 · INSTRUCTION-TUNING 구성

상담 1건마다 分類·요약·질의응답 답 11개 instruction이 생성됩니다

라벨링데이터는 상담 1건에 대해 **분류 5종**, **요약 4종**, **질의응답 2종** (의문사형·예/아니요형, 문항 수는 상담마다 다름)의 instruction을 만들어 냅니다.

Task 유형별 instruction 개수 — Training vs Validation




분류 — 세부 유형 (Training)

5종 모두 균등 (상당당 1문항씩)




요약 — 세부 유형 (Training)

4종 모두 균등



질의응답 — 세부 유형 (Training)

의문사형이 예/아니요형의 1.7배



04 · 출력 길이 분석

output 길이는 task 종류가 거의 전부를 결정합니다

전체 output 길이를 뭉뚱그리면 왜곡되지만, task별로 나누면 아주 뚜렷합니다: 분류는 단어 하나, 질의응답은 짧은 문장, 요약은 완전한 문단입니다.

5.2자

18.7자


164.7자

분류 output 평균 (2~19자)


질의응답 output 평균 (1~127자)

요약 output 평균 (34~1,346자)


분류 output 글자수



질의응답 output 글자수



요약 output 글자수



05 · 실제 예시

Instruction / Output 실제 샘플