

EXPLORATORY DATA ANALYSIS

공공 민원 상담 데이터셋 — 탐색적 데이터 분석

AI Hub မှ ဒေါင်းလုဒ်ရယူထားသော ကိုရီးယား "공공 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터" ကို zip ဖိုင် ၂၄ ခုအတွင်းမှ JSON ဖိုင် ၁၂၁,၃၆၆ ခုလုံးကို တိုက်ရိုက်ဖွင့်ဖတ်ပြီး လေ့လာသုံးသပ်ထားသည့် EDA dashboard ဖြစ်သည်။ ဤဒေတာသည် ဌာန ၁၇ ခု (ယဉ်ကျေးမှုအဖွဲ့အစည်း၊ ဗဟိုအစိုးရဌာန၊ ဒေသန္တရအစိုးရ) ၏ မေးမြန်းချက်များကို Training/Validation နှစ်ပိုင်းခွဲပြီး 分類(classification)၊ 요약(summary)၊ 질의응답(QA) — task သုံးမျိုးအတွက် instruction-tuning ပုံစံဖြင့် label တပ်ထားသည်။

출처 AI Hub · 24.공공 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터 생성 scripts/eda.py

9,132

원본 상담 건수 (원천데이터)

Training 8,085 · Validation 1,047

112,234

Instruction 샘플 (라벨링데이터)

Training 99,745 · Validation 12,489

17

데이터 출처 기관 수

문화기관 1 · 중앙행정기관 3 · 지방행정기관 13

24 zip

원본 압축 파일

JSON 121,366개 · 약 696MB


01 · 기관 구성

ဒေတာက ဌာနအမျိုးအစား ၃ မျိုးမှ လာသည်

zip ဖိုင်အမည်များက TS_국립아시아문화전당 / TS_중앙행정기관 / TS_지방행정기관 ဟု ခွဲထားပြီး၊ ၎င်းအောက်တွင် ဗဟိုဌာန ၃ ခု (고용노동부 · 국토교통부 · 중소벤처기업부) နှင့် ဒေသန္တရအစိုးရ ၁၃ ခု

ပါဝင်သည်။

기관 유형별 상담 건수 — Training vs Validation



커버리지 주의: Validation에는 17개 출처 기관 중 5개(고용노동부·국토교통부·중소벤처기업부·성남시·안양시)만 포함되어 있습니다. 서울시·제주특별자치도를 포함한 지방행정기관 11곳은 Validation에 전혀 등장하지 않으므로, Validation 성능만으로 전체 지역 커버리지를 판단하기는 어렵습니다.

기관별 상담 건수 순위 (Training, 17개 출처)

▶ 국토교통부가 최다, 의정부시가 최소

국토교통부	1,870건
서울시	1,435건
고용노동부	1,080건
중소벤처기업부	1,014건
국립아시아문화전당	841건
성남시	798건
제주특별자치도	420건

부서(consulting_category) 상위 항목

미분류·"-" 제외, 실제 부서명만 표시 (문화기관은 전량 미분류)

건설안전과	207건
경영 전략	207건
건축안전과	174건
인사/노무	168건
수출입	167건
대중교통과	138건

자치구/시/군	건수
천안시	146건
부천시	119건
화성시	106건
안양시	93건
경상북도	85건
용인시	27건
파주시	16건
경상남도	11건
울산광역시	9건
의정부시	6건

민원상담 데이터 EDA	
건설과	84건
문화관광	10건

02 · 핵심 발견

문화전당은 "전화상담", 나머지는 "서면 민원"입니다

consulting_content의 시작 문구를 전수 검사한 결과, **국립아시아문화전당**(97%)은 상담원↔고객의 전화 통화 **전사록**이고, **중앙·지방행정기관**(99%+)은 제목/질문/답변으로 구성된 **서면 민원 Q&A**입니다. 같은 컬럼(consulting_content)이지만 성격이 전혀 다른 두 종류의 텍스트가 섞여 있다는 점은, 모델 학습·평가 시 반드시 고려해야 할 구조적 특징입니다.

PHONE · 국립아시아문화전당

source_id 001899 · consulting_turns 42 · consulting_length 411자

상담원: 안녕하세요? 국립 아시아 문화 전당 ▲▲▲입니다. 제가 무엇을 도와드릴까요?

고객: 저희가 내일 2시 30분에 어... 전당 투어를 예약을 했는데 관련해서 좀 알아보려고요.

상담원: 네. 어떤 것 때문에 궁금하신건가요?

WRITTEN · 고용노동부

source_id 701133 · consulting_turns 2 · consulting_length 160자

Q : 프리랜서 2차 긴급재난지원금을 관계부처의 잘못된 안내로 이의제기 기간이 지났다고 50만 원을 못 받는다고 해서 문의드립니다. 확인 부탁드립니다.

A : 우리 부 빠른 인터넷 상담은 일반적인 고용노동 관련 사항에 대한 간단히 답변하는 창으로, 전사록처럼 질문과 답변이 반복되는 서면 상담은 아닙니다.

상담원: 네, 어떤 건 때문에 그러십니까?

고객: 전당 투자를 하게 되면 음... 어떤 코스로 이어지는지 혹시 좀 전시 위주로 보고 싶은데요.

상담원: 고객님 전당 투어는요. 투어 신청을 고객님의게서 직접 하셨을 때 홈페이지에서 확인 가능합니다만...

상담원/고객 발화가 번갈아 이어지는 대화체 · 평균 40턴

민원상담 데이터 EDA


민원상담 데이터의 특징을 살펴볼 것입니다.

1차 150만 원 지원이 이루어진 기수혜자 2차 50만 원 지원대상은 코로나19 긴급 고용안정지원금을...

Q(질문) → A(답변) 1회 교환으로 끝나는 게시판형 민원 · 항상 2턴

턴(turn) 수 분포 — 형식별 비중 (Training, 각 형식 내 %)

서면 민원은 100%가 "2턴"에 몰려 있고, 전화상담은 20턴 이상에 폭넓게 퍼져 있습니다




03 · INSTRUCTION-TUNING 구성

상담 1건마다 分類·요약·질의응답 11개 instruction이 생성됩니다


라벨링데이터는 상담 1건에 대해 **분류 5종**, **요약 4종**, **질의응답 2종** (의문사형·예/아니요형, 문항 수는 상담마다 다름)의 instruction을 만들어 냅니다.

Task 유형별 instruction 개수 — Training vs Validation




분류 — 세부 유형 (Training)

5종 모두 균등 (상담당 1문항씩)




요약 — 세부 유형 (Training)

4종 모두 균등



질의응답 — 세부 유형 (Training)

의문사형이 예/아니요형의 1.7배



04 · 출력 길이 분석


output 길이는 task 종류가 거의 전부를 결정합니다

전체 output 길이를 뭉뚱그리면 왜곡되지만, task별로 나누면 아주 뚜렷합니다: 분류는 단어 하나, 질의응답은 짧은 문장, 요약은 완전한 문단입니다.

5.2자

분류 output 평균 (2~19자)


분류 output 글자수



18.7자

질의응답 output 평균 (1~127자)


질의응답 output 글자수



164.7자

요약 output 평균 (34~1,346자)

요약 output 글자수



05 · 실제 예시

Instruction / Output 실제 샘플

Validation 데이터에서 그대로 가져온 실제 instruction-output 쌍입니다. input은 상담 원문 전체(1,500~1,900자)이므로 생략했습니다.

분류 · 상담 주제

"교통", "환경", "안전", "복지", "문화", "경제", "주택/건설", "기타(국방/세무/방송통신/경찰 등)" 중에서 상담 주제를 선택해 줘.

질의응답 · 의문사형

고객은 언제로 어린이 체험관 단체 예약을 잡았어?

OUTPUT

9월 21일

요약 · 길이 제한 요약

민원인의 질문을 100자 이하, 한 문장으로 요약해 줘.

OUTPUT

OUTPUT
문화

인천 서구가 투기과열지구였다가 비조정 지역이 되었는데, 분양 시 전매제한이 5년이었던 아파트의 전매제한 기한이 변경되는지 궁금하다.

다른 세부 유형 instruction 예시

TASK	INSTRUCTION	OUTPUT
분류·상담 내용	이번 상담은 "일반 민원 상담", "고충 민원 상담", "다수기관 복합 민원 상담" 중에 뭐지?	일반 민원 상담
분류·상담 결과	상담 결과는 "만족", "미흡", "해결 불가", "추가 상담 필요" 중 어느 쪽에 속해?	만족
분류·상담 사유	이 민원이 발생한 책임은 "기관"에 있니, 아니면 "민원인"에게 있니?	민원인
분류·상담 요건	이 상담이 "단일 요건 민원"과 "다수 요건 민원" 중 어디에 속하는지 알려줘.	다수 요건 민원
질의응답·예/아니요형	고객은 SNS 수신만 하겠다고 했어?	아니, SNS와 이메일 2가지 모두 수신하겠다고 했어.
요약·핵심 정보 추출	건축물의 연면적 계산에 대한 건설안전과의 답변에서 핵심 정보를 요약해 줘.	건축물의 연면적을 계산할 때 원칙적으로는 동별로 계산하지만 2동 이상이 하나의 구조로 연결되거나...
요약·주제 중점 요약	지하안전관리에 대한 특별법에 따른 안전관리계획 제출기관에 대해 요약해 줘.	지하개발사업자는 건설사업자와 주택건설등록업자가 지하안전평가 협의 내용 등을 안전관리계획에 반영하게 하여...

06 · 파일 인벤토리

디스크에 있는 zin 24개 전체 목록

모든 수치는 각 zip을 직접 열어 json_count를 실제로 센 값입니다 (추정치 아님).

SPLIT	종류	파일명	크기(MB)	JSON 개수
Training	01.원천데이터	TS_국립아시아문화전당.zip	1.37	841
Training	01.원천데이터	TS_중앙행정기관.zip	5.51	3,964
Training	01.원천데이터	TS_지방행정기관.zip	4.20	3,280
Training	02.라벨링데이터	TL_국립아시아문화전당_분류.zip	7.67	4,207
Training	02.라벨링데이터	TL_국립아시아문화전당_요약.zip	6.64	3,462
Training	02.라벨링데이터	TL_국립아시아문화전당_질의응답.zip	5.10	2,817
Training	02.라벨링데이터	TL_중앙행정기관_분류.zip	31.21	19,820
Training	02.라벨링데이터	TL_중앙행정기관_요약.zip	27.63	16,523
Training	02.라벨링데이터	TL_중앙행정기관_질의응답.zip	21.20	13,302
Training	02.라벨링데이터	TL_지방행정기관_분류.zip	24.10	16,401
Training	02.라벨링데이터	TL_지방행정기관_요약.zip	20.45	13,295
Training	02.라벨링데이터	TL_지방행정기관_질의응답.zip	14.59	9,918
Validation	01.원천데이터	VS_국립아시아문화전당.zip	0.17	105
Validation	01.원천데이터	VS_중앙행정기관.zip	0.78	520
Validation	01.원천데이터	VS_지방행정기관.zip	0.59	422
Validation	02.라벨링데이터	VL_국립아시아문화전당_분류.zip	0.97	525
Validation	02.라벨링데이터	VL_국립아시아문화전당_요약.zip	0.82	421

Validation	02.라벨링데이터	VL_국립아시아문화전당_질의응답.zip	0.59	325
Validation	02.라벨링데이터	VL_중앙행정기관_분류.zip	4.39	2,600
Validation	02.라벨링데이터	VL_중앙행정기관_요약.zip	3.62	2,081
Validation	02.라벨링데이터	VL_중앙행정기관_질의응답.zip	2.61	1,570
Validation	02.라벨링데이터	VL_지방행정기관_분류.zip	3.36	2,110
Validation	02.라벨링데이터	VL_지방행정기관_요약.zip	2.77	1,686
Validation	02.라벨링데이터	VL_지방행정기관_질의응답.zip	1.84	1,171

샘플 워본 파일: 3.개방데이터/1.데이터/samples/ (zip당 3개씩. 총 72개. prettv-print 완료)