

SUBMISSION AUDIT

Final_submission.pdf — 데이터 검증 리포트

27페이지 제안서의 각 슬라이드가 실제 어떤 데이터·코드·EDA 결과에 근거하는지 확인한 문서입니다.
이번 제출은 **구현 단계가 아니라 제안서 단계**라서, "코드가 완성됐는가"가 아니라 **"데이터를 정확히 이해하고 근거를 갖고 설계했는가"**에 초점을 맞췄습니다.

SLIDE	내용	근거(코드/데이터)	상태
p.8	AI-Hub Dataset 개요 (121,366 Q&A JSONs)	eda_stats.json	표현 부정확
p.9	데이터셋 3종 소개	범용데이터리스트.pdf	일치
p.10	Training/Validation 건수 표	scripts/eda.py	일치
p.11	[그림3] 카테고리 불균형	scripts/visualize.py → 08_category_distribution.png	동일 파일
p.12	[그림4] 포맷 이중성	scripts/visualize.py → 02_format_duality.png	동일 파일
p.13	[그림5] 입력 글자수 분포	scripts/visualize.py → 07_input_length_distribution.png	동일 파일
p.14-15	전처리 프로세스 5단계	EDA 발견 기반 신규 설계	EDA 근거 확인 필요
p.16-18	Stage 1/2/3 Input·Output 표	직접 정리한 표 그대로	일치
p.19-21	모델 선정 이유	klue/RoBERTa-large, BGE-m3, EEVE 스펙	실제 실험 모델과 다름

01 · 데이터셋 (P.9-10)

3종 데이터셋 + 건수 표

p.9의 3가지 데이터 구분(민원 학습 데이터 / 국가 법령 / 대전시 조례)은 팀이 만든 「AIP2 범용데이터리 스트.pdf」 와 제가 만든 RAG 법령 가이드의 카테고리 매핑을 그대로 반영한 것으로, 실제 law.go.kr·elis.go.kr 링크와 일치합니다. p.10의 숫자는 scripts/eda.py 가 121,366개 JSON 파일 전체를 zip에서 직접 열어 센 값입니다 (추정치 아님).

[표3] 민원 학습 데이터셋 수 — 재검증

✓ 일치

원천 상담 Training	8,085	원천 상담 Validation	1,047
Instruction 샘플 Training	99,745	Instruction 샘플 Validation	12,489
분류(상담 주제) Training	8,088	분류(상담 주제) Validation	1,047

Training의 원천 상담(8,085)과 분류 subset(8,088)이 3건 차이 나는 건 오타가 아니라, 라벨링 zip 파일 일부에 원천데이터보다 극소수 더 많은 레코드가 들어있어서 생기는 실제 차이입니다.

02 · EDA 그래프 3개 (P.11-13)

[그림3][그림4][그림5] — 제가 만든 PNG와 동일 파일

3개 그래프 전부 scripts/visualize.py 가 eda_stats.json (121,366개 JSON 전수 분석 결과)에 서 직접 생성한 파일입니다. Canva에 붙여넣은 이미지가 이 PNG들과 픽셀 단위로 동일합니다.

[그림3] 카테고리 불균형 — 08_category_distribution.png

✓ 동일 파일

상담 주제(8-카테고리) Class 분포 — Training




주택/건설(1,982)과 기타(182)의 차이가 약 11배 — Training 데이터의 output 필드를 train_sft.jsonl 에서 직접 카운트한 값입니다.

[그림4] 포맷 이중성 — 02_format_duality.png

✓ 동일 파일

포맷 이중성 — 전화상담 vs 서면 민원 톤 분포




전화상담(국립아시아문화전당, n=812)과 서면 민원(나머지 16개 기관, n=7,219)의 consulting_content 시작 문구("상담원:" vs "Q:":"/"제목")를 전수 검사해서 나눈 결과입니다.

[그림5] 입력 글자수 분포 — 07_input_length_distribution.png

✓ 동일 파일

입력(input) 글자수 분포 — 전화상담 vs 서면 민원



같은 형식 구분(전화/서면)을 consulting_length (글자수) 기준으로 다시 나눈 것 — 턴 수는 전화가 훨씬 많지만(그림4), 글자수 자체는 전화가 250~500자에 집중, 서면은 0~250자에 더 많이 분포합니다.

03 · 전처리 프로세스 (P.14-15)

5단계가 어떤 EDA 발견에서 나온 것인지

제안서의 전처리 5단계는 위 3개 그래프의 발견을 실제 작업으로 옮긴 것입니다. 단계별로 근거를 연결했습니다.

1 텍스트 정제 — 화자 태그를 구조화된 Q&A 쌍으로 정규화

전화상담("상담원:"/"고객:")과 서면 민원("Q:"/"A:")이 서로 다른 태그 체계를 쓴다는 [그림4]의 포맷 이중성 발견을 그대로 실행에 옮긴 단계입니다 — 두 형식을 하나의 구조로 통일해야 모델이 일관되게 학습합니다.

2 개인정보 이중 마스킹 — NER 기반 2차 스캔

원본 데이터에 이미 "▲▲▲" 마스킹이 적용돼 있다는 사실(원천데이터 샘플에서 직접 확인)을 전제로, 놓친 개인정보를 잡아내는 검증 레이어를 추가한 것입니다. 원 데이터 상태를 정확히 파악했다는 근거가 됩니다.

3 카테고리 정제 및 재라벨링 — 무관 기관 데이터는 EEVE 톤 학습에만 사용

"목표 카테고리 와 무관한 기관 데이터는 분류 모델(klue/RoBERTa-large) 학습에서는 제외"라는 문장이 핵심입니다 — 이걸 [그림4]에서 확인된 **도메인 불일치 위험**(대전시는 서면 형식일 가능성이 높는데, 학습 데이터엔 전화상담 812건이 섞여 있음)에 대한 실제 해결책입니다. 전화상담 데이터를 분류기 학습에서 빼고 EEVE 톤 학습에만 남겨두는 절충안으로, 이전 대화에서 제기했던 우려를 구체적인 방법으로 풀어낸 것입니다.

4 법령·조례 조항 단위 청킹

Stage 2(BGE-m3) 표의 "색인 시 Input: 법령·조례 조문 chunk(조·항·호 단위)"와 정확히 같은 내용을 전처리 관점에서 다시 설명한 것입니다.

5 데이터 분할 — 케이스 단위로 Train/Validation/Test 분할

AI-Hub는 Training/Validation 2종만 제공하고 Test는 없다는 점은 이전 대화에서 확인한 사실입니다. "케이스 단위 분할"이라는 표현은 이 부분을 팀이 직접 만들겠다는 뜻으로 읽힙니다 — 다만 **어느 데이터를 Test로 쓸지**(AI-Hub Validation을 Test로 쓸지, Training을 다시 쪼갤지)는 슬라이드에 명시돼 있지 않아 발표 때 질문이 나올 수 있는 지점입니다.

04 · 실제로 한 것과 제안서의 차이

코드로 실험한 모델 ≠ 제안서에 쓴 모델


제안서 단계이므로 문제는 아니지만, 발표 때 "왜 이 모델을 선택했나" 질문에 정확히 답하려면 이 차이를 알고 있어야 합니다


차이점

scripts/compare_classifiers.py 로 실제 fine-tuning까지 돌려서 비교한 모델은 **KoBERT(skt/kobert-base-v1)**와 **KR-BERT(snunlp/KR-BERT-char16424)**입니다 — 이건 처음에 Professor가 제시한 후보군이었습니다. 반면 제안서(p.16, p.19)에 최종적으로 쓴 건 이 후보군에 없던 **klue/RoBERTa-large**입니다. 즉 **klue/RoBERTa-large**는 아직 실제로 fine-tuning해서 정확도를 확인해보지 않은 모델입니다 — 제안서 단계이므로 "이 모델을 쓸 계획"이라고 설명하는 것 자체는 문제없지만, 실제 실험 결과(아래)와 혼동하지 않아야 합니다.

실제 실험 결과 (참고용) — 06_classifier_comparison.png

부록 자료





KoBERT: accuracy 0.312 / macro-F1 0.173 (36.8분) · KR-BERT: accuracy 0.688 / macro-F1 0.629 (38.0분)

※ dropout을 강제로 끈 상태(로컬 PC의 PyTorch 버그 우회) + class당 150~200건짜리 축소 데이터로 돌린 pilot이라 절대적 정확도는 낮습니다. "후보군 중 어느 쪽이 이 조건에서 상대적으로 더 잘 배우는가"를 보기 위한 참고 자료이며, klue/RoBERTa-large의 성능을 예측하는 근거로는 쓸 수 없습니다.

05 · 재확인 — P.8 표현

"121,366 Q&A JSONs" 표현은 여전히 부정확합니다

정확한 내용

121,366 = 원천 상담 9,132건(전화 대화 전사록/서면 Q&A 혼합, "Q&A"만은 아님) + Instruction 112,234건(분류 45,663 + 요약 37,468 + 질의응답 29,103). 즉 "질의응답"은 전체의 4분의 1 정도(29,103건)뿐이고 나머지는 분류·요약입니다. 발표 때 "이 12만 건이 다 Q&A냐"는 질문이 나오면 정정할 준비를 해두는 게 좋습니다.

코드 파일 — `scripts/eda.py` (통계 산출) · `scripts/prepare_dataset.py` (SFT jsonl 변환) · `scripts/visualize.py` (그림3/4/5 생성) · `scripts/compare_classifiers.py` (KoBERT/KR-BERT 실험)